

# MODELE Z INTERAKCJAMI I WIELOMIANAMI

EKONOMETRIA WNE 2022/23

---


Sebastian Zalas

1 grudnia 2022

# WPROWADZENIE

- Sposoby uchwycenia nieliniowej relacji między zm. zależną i niezależną:
  - umieszczenie wielomianu zm. niezależnej
  - interakcje
- Przykład: **TestScore** vs **Income**, **STratio**
  - dane `CASchools` - dostępne w pakiecie `AER`
  - **TestScore** - łączny wynik testu z matematyki i czytania; średnia w dystrykcie
  - **Income** - średni dochód w dystrykcie
  - **STratio** - stosunek liczby nauczycieli do liczby uczniów

## WYNIK TESTU VS DOCHÓD



Wyraźnie relacja pomiędzy TestScore oraz Income jest nieliniowa

## MODEL Z WIELOMIANEM ZM. ZALEŻNEJ

- Jak uchwycić nieliniową relację?

⇒ Przybliżenie zm. zależnej wielomianem:

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{1,i}^2 + \beta_3 x_{1,i}^3 + \dots + \beta_k x_{1,i}^k + \varepsilon$$

- to zwykły model liniowy - mimo podniesionych do potęgi regresorów
- parametry takiego modelu są trudne do interpretacji, ale interpretowanie wyników regresji jest możliwe

## MODEL Z WIELOMIANEM ZM. NIEZALEŻNEJ - PRZYKŁAD

- Relacja między *TestScore* i *Income* (średni dochód w dystrykcie per capita)

⇒ Oszacowanie modelu z kwadratem dochodu


$$TestScore_i = 607.302 + 3.85099Income_i - 0.04231Income_i^2 + \varepsilon_i$$

⇒ Oszacowanie modelu z sześciannym dochodu

$$TestScore_i = 600.079 + 5.018677Income_i - 0.09580521Income_i^2 + \\ 0.0006854851Income_i^3 + \varepsilon_i$$

## MODEL Z WIELOMIANEM ZM. NIEZALEŻNEJ - INTERPRETACJA


■ Zrób wykres wartości dopasowanych



Model z kwadratem zm. zależnej jest lepiej dopasowany do danych

## MODEL Z WIELOMIANEM ZM. NIEZALEŻNEJ - INTERPRETACJA

■ Czy model z wielomianem 3. stopnia jest lepszy?



Wielomian 3. stopnia nie poprawia sytuacji...

## MODEL Z WIELOMIANEM ZM. NIEZALEŻNEJ - INTERPRETACJA

- Policz zmiany (dla modelu z kwadratem):

$$\Delta y_i = \beta_1 \Delta x_{1,i} + \beta_2 \Delta x_{1,i}^2$$

w przybliżeniu:

$$\Delta y_i \approx \beta_1 + 2\beta_2 x_{1,i}$$

- Przykład:

$$\Delta \hat{TestScore}_i = 3.85099 - 2 \times 0.04231 \text{Income}_i$$

- dla zmiany dochodu o 1 jeden tysiąc, przy dochodzie wynoszącym 10 tysięcy:

$$\begin{aligned} \Delta \hat{TestScore}_i &= 3.85099 - 2 \times 0.04231 \times 10 \\ &= 3.005 \end{aligned}$$

- czyli zmiana dochodu o 1 tysiąc, jest związana ze wzrostem wyniku testu średnio o 3.005 punktu (w przybliżeniu)



## MODEL Z WIELOMIANEM ZM. NIEZALEŻNEJ - INTERPRETACJA

- Zmiany zależą od poziomu zmiennej zależnej
- Możemy policzyć zmiany wartości dopasowanych dla wybranych, konkretnych przedziałów
- Przykład:


Zmiana w <i>Income</i> o 1000 per capita	$\Delta TestScore$
z 5 na 6 tys. pc	3.3856
z 10 na 11 tys. pc	2.9625
z 25 na 26 tys. pc	1.6933
z 45 na 46 tys. pc	0.0009

## MODEL Z WIELOMIANEM ZM. NIEZALEŻNEJ - PODSUMOWANIE

- Model z wielomianem zm. zależnej estymujemy MNK
- Współczynniki mają skomplikowaną interpretację
- Aby zinterpretować oszacowania:
  - zrób wykres
  - oblicz przewidywane  $\frac{\Delta y}{\Delta x}$  dla różnych wartości  $x$ .
- Sposoby wyboru stopnia wielomianu  $k$ : sprawdź wrażliwość oszacowań w różnych wariantach, osąd własny, a także korzystamy ze statystyk  $t$  oraz  $F$  (w przyszłości)

## INTERAKCJE

■ Czy dostrzegamy tu jakiś rodzaj nieliniowości?



Na pierwszy rzut oka, relacja między Test Score a Student-Teacher ratio nie wydaje się nieliniowa...

## INTERAKCJE

- Przyjrzyjmy się modelowi:

$$TestScore = \beta_0 + \beta_1 STratio + \varepsilon$$

gdzie

- *TestScore* - średni wyniku testu uczniów w Kalifornii w danym dystrykcie
- *STratio* - stosunek liczby nauczycieli do liczby uczniów

- Zwykle mniej uczniów na jednego nauczyciela, oznacza bardziej indywidualne podejście...

⇒ ... ale czy ta zależność jest zawsze taka sama? **NIE!**

## INTERAKCJE

- Przyjrzyjmy się modelowi:

$$TestScore = \beta_0 + \beta_1 STratio + \varepsilon$$

gdzie

- *TestScore* - średni wyniku testu uczniów w Kalifornii w danym dystrykcie
- *STratio* - stosunek liczby nauczycieli do liczby uczniów

- Zwykle mniej uczniów na jednego nauczyciela, oznacza bardziej indywidualne podejście...

⇒ ... ale czy ta zależność jest zawsze taka sama? **NIE!**

## INTERAKCJE

- Przyjrzyjmy się modelowi:

$$TestScore = \beta_0 + \beta_1 STratio + \varepsilon$$

gdzie

- *TestScore* - średni wyniku testu uczniów w Kalifornii w danym dystrykcie
- *STratio* - stosunek liczby nauczycieli do liczby uczniów

- Zwykle mniej uczniów na jednego nauczyciela, oznacza bardziej indywidualne podejście...

⇒ ... ale czy ta zależność jest zawsze taka sama? **NIE!**

## INTERAKCJE

- Być może zmniejszenie klasy jest zróżnicowana w zależności od okoliczności...
- Być może uczniowie uczący się angielskiego mogą bardziej potrzebować uwagi nauczyciela..
- To znaczy:  $\frac{\Delta TestScore}{\Delta Stratio}$  może zależeć od  $Pc\_EL$  (procent uczniów uczących się angielskiego)
- Bardziej ogólnie  $\frac{\Delta Y}{\Delta X_1}$  może zależeć od  $X_2$
- Jak modelować takie **interakcje**?

⇒ Najpierw zmienne binarne, później zmienne ciągłe.

## INTERAKCJE - ZMIENNE BINARNE

$$y_i = \beta_0 + \beta_1 D_{1,i} + \beta_2 D_{2,i} + u_i$$

- $D_{1,i}, D_{2,i}$  są zmiennymi zero-jedynkowymi
- Spójrzmy na  $\beta_1$ 
  - mierzy efekt zmiany z  $D_1 = 0$  na  $D_2 = 1$
  - w takiej specyfikacji **ten efekt jest niezależny od wartości  $D_2$**
- Aby zbadać zależność między zmianą  $D_1$  a  $D_2$ , musimy uwzględnić **interakcję**  $D_1 \times D_2$  jako regresor:

$$y_i = \beta_0 + \beta_1 D_{1,i} + \beta_2 D_{2,i} + \beta_3 (D_{1,i} \times D_{2,i}) + u_i$$



## INTERAKCJE - ZMIENNE BINARNE

$$y_i = \beta_0 + \beta_1 D_{1,i} + \beta_2 D_{2,i} + u_i$$

- $D_{1,i}, D_{2,i}$  są zmiennymi zero-jedynkowymi
- Spójrzmy na  $\beta_1$ 
  - mierzy efekt zmiany z  $D_1 = 0$  na  $D_2 = 1$
  - w takiej specyfikacji **ten efekt jest niezależny od wartości  $D_2$**
- Aby zbadać zależność między zmianą  $D_1$  a  $D_2$ , musimy uwzględnić **interakcję**  $D_1 \times D_2$  jako regresor:

$$y_i = \beta_0 + \beta_1 D_{1,i} + \beta_2 D_{2,i} + \beta_3 (D_{1,i} \times D_{2,i}) + u_i$$

## INTERAKCJE - ZMIENNE BINARNE - INTERPRETACJA

$$y_i = \beta_0 + \beta_1 D_{1,i} + \beta_2 D_{2,i} + \beta_3 D_{1,i} \times D_{2,i} + u_i$$

- Ogólna zasada: porównaj przypadki:

$$\mathbb{E}(y_i | D_{1,i} = 0, D_{2,i} = d_2) = \beta_0 + \beta_2 d_2 \quad (1)$$

$$\mathbb{E}(y_i | D_{1,i} = 1, D_{2,i} = d_2) = \beta_0 + \beta_1 + \beta_2 d_2 + \beta_3 d_2 \quad (2)$$

odejmijmy (2) - (1) :

$$\mathbb{E}(y_i | D_{1,i} = 1, D_{2,i} = d_2) - \mathbb{E}(y_i | D_{1,i} = 0, D_{2,i} = d_2) = \beta_1 + \beta_3 d_2$$

- Wpływ  $D_1$  zależy od  $d_2$  (wartość zm.  $D_2$ )
- $\beta_3$  = wpływ zmiany  $D_1$  gdy  $D_2 = 1$

## INTERAKCJE - ZMIENNE BINARNE - PRZYKŁAD

- Zależność *TestScore*, *STratio*, *hiEL* oraz *hiSTr*

- $hiEL = 1$  jeżeli  $PctEL \geq 10$

- $hiSTr = 1$  jeżeli  $STratio \geq 20$

- Oszacowanie:

$$TestScore = 664.1 - 18.2hiEL - 1.9hiSTr - 3.5(hiSTr \times hiEL)$$

- "Wpływ" *hiSTr* gdy *hiEL* = 0 wynosi -1.9

- "Wpływ" *hiSTr* gdy *hiEL* = 1 wynosi  $-1.9 - 3.5 = -5.4$

- Zmniejszenie liczby uczniów do nauczycieli ma większy efekt, gdy procent uczących się angielskiego jest duży

## INTERAKCJE - ZMIENNE BINARNA I CIĄGŁA

- Interakcja między zmienną ciągłą i binarną:

$$y_i = \beta_0 + \beta_1 D_i + \beta_2 x_i + u_i$$

- $D_i$  to zm. binarna,  $x_i$  to zm. ciągła
- w powyższym modelu wpływ  $x_i$  na  $y_i$ , czyli  $\beta_2$ , nie zależy od  $D_i$
- aby sprawdzić jak  $x_i$  wpływa na  $y_i$  w zależności  $D_i$  trzeba wprowadzić do modelu interakcję,  $D_i \times x_i$  jako zm. objaśniającą:

$$y_i = \beta_0 + \beta_1 D_i + \beta_2 x_i + \beta_3 D_i \times x_i + u_i$$

## INTERAKCJE - ZMIENNE BINARNA I CIĄGŁA

- Dwie linie regresji:

$$y_i = \beta_0 + \beta_1 D_i + \beta_2 x_i + \beta_3 D_i \times x_i + u_i$$

- przypadek z  $D_i = 0$

$$y_i = \beta_0 + \beta_2 x_i + u_i$$

- przypadek z  $D_i = 1$

$$y_i = \beta_0 + \beta_1 + \beta_2 x_i + \beta_3 x_i + u_i$$

$$y_i = (\beta_0 + \beta_1) + (\beta_2 + \beta_3)x_i + u_i$$

## INTERAKCJE - ZMIENNE BINARNA I CIĄGŁA - INTERPRETACJA

$$y_i = \beta_0 + \beta_1 D_i + \beta_2 x_i + \beta_3 D_i \times x_i + u_i$$

- Ogólna zasada: porównaj przypadki:

$$y_i = \beta_0 + \beta_1 D_i + \beta_2 x_i + \beta_3 D_i \times x_i \quad (3)$$

- Zmieńmy  $x_i$

$$y_i + \Delta y_i = \beta_0 + \beta_1 D_i + \beta_2 (x_i + \Delta x_i) + \beta_3 D_i \times (x_i + \Delta x_i) \quad (4)$$

- odejmijmy (4) - (3)

$$\Delta y_i = \beta_2 \Delta x_i + \beta_3 D_i \Delta x_i$$

$$\frac{\Delta y_i}{\Delta x_i} = \beta_2 + \beta_3 D_i$$

## INTERAKCJE - ZMIENNE BINARNA I CIĄGŁA - PRZYKŁAD

- Zależność *TestScore*, *STratio* i *hiEL* (*hiEL* = 1 jeżeli *PctEL*  $\geq$  10)

- Oszacowanie:

$$TestScore = 682.2 - 0.97STratio + 5.6hiEL - 1.28(STratio \times hiEL)$$

- gdy *hiEL* = 0:

$$TestScore = 682.2 - 0.97STratio$$

- gdy *hiEL* = 1:

$$\begin{aligned} TestScore &= 682.2 - 0.97STR + 5.6 - 1.28STratio \\ &= 687.8 - 2.25STratio \end{aligned}$$

- w efekcie otrzymujemy dwie regresje, każda dla jednego przypadku zmiennej *hiEL*
- Obniżenie liczby uczniów przypadających na jednego nauczyciela ma silniejszy wpływ na wyniki uczniów, gdy udział uczniów uczących się angielskiego jest duży.

Pytania? Wątpliwości?  
Dziękuję!

**e:** [s.zalas@uw.edu.pl](mailto:s.zalas@uw.edu.pl)